

지속가능성: AI 에너지 효율화와 엣지 컴퓨팅

김말희 한국전자통신연구원 환경ICT연구실 책임연구원

정 훈 한국전자통신연구원 환경ICT연구실 책임연구원

1. 머리말: AI 확산과 에너지 문제

챗-GPT(Chat-GPT), 제미니(GEMINI), 딥시크(DeepSeek) 등 LLM(거대언어모델, Large Language Model)과 생성형 AI(Artificial Intelligence)의 빠른 확산은 산업 및 사회 전반에 새로운 혁신을 불러왔다. AI는 이제 단순한 질의응답을 넘어, 코드 자동 생성, 문서 작성, 의료·제조 데이터 분석, 음악·회화·동영상 제작에 이르기까지 다양한 영역에서 필수적인 도구로 자리 잡고 있다. AI 인프라 시대가 본격적으로 도래하면서 인간의 창의성은 이러한 인프라 위에서 더욱 꽃피울 것으로 전망된다.

그러나 이러한 AI 기술의 비약적인 발전과 모델의 초대형화는 불가피하게 막대한 연산 자원을 요구한다. 데이터센터의 전력 소비와 탄소 배출이 가파르게 증가하고 있으며, 이는 지구 환경 지속가능성의 또 다른 위협 요인이 되고 있다. 사용 전력량의 증가는 기업의 운영 비용을 크게 증가시키는 것은 물론, 글로벌 ESG(환경·사회·지배구조, Environment, Social and Governance) 경쟁력과 탄소규제 대응 능력까지 좌우하는 중요한 과제가 되고 있다.

AI가 산업과 사회의 구조를 빠르게 변화시키면서, 이제 산업과 지구 환경의 지속가능성은 AI 기술 에너지 효율화와 떼려야 뗄 수 없이 연결되고 있다. 이러한 AI 에너지 효율화 기술은 산업 경쟁력과 환경 보전을 동시에 실현하기 위한 핵심축으로 점점 더 중요해지고 있다[1].

이에 이번 원고에선 AI 에너지 효율화와 엣지 컴퓨팅의 동향을 살펴보고, 이를 뒷받침하는 ICT 표준화와 시험·인증의 필요성, 그리고 관련 전략을 함께 고찰하고자 한다.

2. AI 에너지 소비 문제 현황 및 기업·환경 리스크

2.1 AI 데이터센터의 전력 소비 급증

GPT-3, GPT-4와 같은 초대형 AI 모델은 수백억~수조 개 파라미터를 학습하며, 이 과정에서 수천 개 GPU가 수개월간 가동돼 수천 MWh(Megawatt-hour) 전력이 소모된다. 가트너

(Gartner)에 따르면, 2027년까지 AI 작업을 처리하는 데이터센터의 40%가 전력 공급 부족 문제에 직면할 것으로 예상되며[2], 냉각 시스템 운영 비용 또한 급증해 전체 전력 소비를 더욱 가중시키고 있다.

또한, 클라우드 기반 AI 서비스 확산으로 인해 데이터 전송과 저장 비용도 급증하고 있으며, 이는 AI 시스템 운영 기업에 상당한 부담을 초래하고 있다. 따라서 AI 모델 성능을 유지하면서도 에너지 효율성을 극대화하기 위한 새로운 기술적 접근이 필요하다.

가트너는 생성형 AI의 에너지 효율화를 위한 5가지 방법으로, [그림 1]과 같이 최신 하드웨어 사용, 클라우드로의 이관, 온엣지(On-edge) 배치, 소프트웨어와 하드웨어가 공동 설계된 맞춤형 시스템, 소프트웨어 최적화를 제시하고 있다[3]. 단기적으로는 최신 하드웨어 개발 및 사용에 집중하고, 점차적으로 소프트웨어 최적화 중심으로 에너지 효율화 전략 전이가 이뤄질 것으로 전망한다.

2.2 기업 경제성·탄소규제 리스크

AI 에너지 소비 문제는 단순히 기업 운영비 상승에 그치지 않는다. 데이터센터에서 소비되는 전력은 대

부분 화석연료 기반이며, 이에 따른 탄소 배출은 지구 온난화와 기후 변화를 가속한다.

EU(유럽연합, European Union) CBAM(탄소국경조정제, Carbon Border Adjustment Mechanism), ISO 14064(온실가스 관리) 등 글로벌 탄소규제가 강화되면서, 에너지 소비와 탄소 배출을 실시간 모니터링·보고해야 하는 환경규제 리스크 또한 커지고 있다.


3. AI 에너지 효율화 기술 동향

3.1 모델 경량화 및 소프트웨어 최적화

AI 모델 초대형화에 따른 연산량과 메모리 부담을 줄이기 위해 다양한 경량화 및 최적화 기법이 연구되고 있다.

- **MoE(Mixture of Experts)**: 필요한 전문가 계층만 활성화해서 불필요한 연산을 줄인다. 구글(Google) GShard[4], 딥시크MoE[5]가 대표적인 사례다. [그림 2]는 딥시크MoE의 구조로, 공유 전문가와 선택되는 전문가를 혼합해 사용하는 방법을 보여준다.
- **프루닝(Pruning)**: 중요도가 낮은 뉴런·연결을 제거해 추론 시 연산량과 전력 소모를 줄인다[6].
- **양자화(Quantization)**: 숫자 정밀도를 낮춰 연산 및 메모리 사용을 최소화한다[7].

Improving Power Utilization and Efficiency Illustrative



[그림 1] 에너지 효율화 방법

출처: Gartner, 'Emerging Tech: Strategies to Achieve Energy Efficiency Goals for GenAI,' Gartner Report, ID G00809640, 2024[3]

<표 1> AI 하드웨어 기술 및 대표 기업

기술 분야	대표 기업 및 기술	내용
AI 특화 칩셋	구글 TPU, 테슬라 도조, ARM 에토스 NPU, 엔비디아(NVIDIA) A100/H100, Grace Hopper Superchip	전용 AI 학습/추론 칩, GPU 대비 고효율
광 기반 AI 가속기	Lightmatter, Lightelligence, Optalysys	빛 기반 연산으로 초저전력
메모리 중심 AI 연산	엔비디아 HBM3 (Hopper H100), IBM PIM, 삼성전자·SK하이닉스 HBM4	메모리 내 연산, 데이터 이동 최소화
칩렛 및 3D IC 패키징	TSMC CoWoS/SolC, 인텔 포베로스(Foveros) 3D(Meteor Lake), 삼성전자 H-Cube/X-Cube	직접적으로 전송 거리·전력 감소
뉴로모픽 컴퓨팅	인텔 로이히, IBM 트루노스, 퀄컴(Qualcomm), AMD	뇌 모사형 연산, 비동기 저전력

출처: 한국전자통신연구원 환경ICT연구실

- **지식 증류(Knowledge Distillation)**: 대형 모델의 지식을 소형 모델로 이전해 추론 시 전력 사용을 크게 줄인다[8][9].
- **저랭크 근사(Low-Rank Approximation)**: CNN과 같은 딥러닝 네트워크에서 행렬 차원을 축소해 연산을 경량화한다[10].

- **메모리 중심 AI 연산(PIM, HBM)**: 연산을 메모리 내부에서 수행해 데이터 이동에 따른 전력 소모를 줄인다.
- **칩렛·3D 패키징(CoWoS, Foveros)**: 연산-메모리 모듈을 수직 적층해 전송 거리와 전력 사용을 줄인다.
- **인텔(Intel) 로이히(Loihi)[14], IBM 트루노스(TrueNorth) 뉴로모픽 컴퓨팅**: 뇌 신경망을 모방해 초저전력 AI 연산을 실현한다.

3.2 AI 특화 하드웨어


AI 연산의 전력 효율성을 높이기 위해 GPU를 넘어선 전용 AI 프로세서가 빠르게 발전하고 있다.

- **구글 TPU, 테슬라(Tesla) 도조(Dojo)[11], ARM 에토스(Ethos) NPU(Neural Processing Unit)[12]**: AI 연산을 위해 최적화된 특화 칩셋으로, GPU 대비 훨씬 낮은 전력으로 높은 연산 성능을 제공한다.
- **광 기반 AI 가속기(Photonic AI Accelerators)**: 빛을 이용해 연산을 수행, 전자식 회로 대비 전력 효율을 대폭 향상시킨다[13].

4. 엣지 컴퓨팅과 온-디바이스 AI

4.1 엣지 컴퓨팅의 개념과 필요성

엣지 컴퓨팅은 데이터를 중앙의 클라우드로 보내지 않고, 생성된 현장에서 직접 AI 연산을 수행하는 방식



[그림 2] 딥시크MoE 개요

출처: DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models, arXiv preprint, CoRR, vol. 2401, no. 06066, 2024. [5]

<표 2> 엣지 AI vs 온-디바이스 AI

구분	엣지 AI	온-디바이스 AI
정의	데이터 생성 지점 인근 엣지 서버 또는 네트워크 장치에서 AI 연산을 수행	스마트폰, 태블릿, 웨어러블 기기 등 최종 사용자 장치 자체에서 AI 연산을 수행
연산 위치	엣지 서버, 게이트웨이, 로컬 데이터센터	최종 사용자 장치(스마트폰, IoT, 웨어러블 등)
네트워크 필요성	엣지 서버와 연결	독립적 연산 가능
응용 분야	자율주행차, 스마트 팩토리, 의료 AI, CCTV 분석	스마트폰 음성 비서, 실시간 번역, 건강관리
장점	클라우드 대비 저지연, 실시간 데이터 처리	개인정보보호 강화, 네트워크 비용 절감
단점	엣지 서버 구축 필요, 네트워크 연결이 필요한 때도 있음	디바이스의 연산 성능이 제한적

출처: 한국전자통신연구원 환경ICT연구실

이다. 이를 통해 네트워크 비용과 전력 소비를 줄이고, 자율주행·스마트 팩토리·헬스케어 등 실시간 처리가 중요한 분야에서 반응 속도와 에너지 효율을 높인다.

엣지 컴퓨팅의 효과를 극대화하기 위해선 엣지 디바이스와 중앙 시스템 간 효율적인 협업 및 시스템 통합 최적화가 필수다. 추론만을 엣지에서 수행하는 경우도 있고, 추론과 학습을 모두 엣지에서 수행하는 경우도 있다. 예민한 데이터의 경우는 데이터 보안을 위해서 엣지 컴퓨팅을 수행하기도 한다.

4.2 온-디바이스 AI와 엣지 AI 최적화

- **모델 최적화:** 프루닝, 양자화, 지식 증류 등으로 모델을 경량화해 소형 디바이스에서도 AI가 동작하도록 한다.
- **하드웨어 최적화:** ARM 기반 NPU, 구글 엣지 TPU(Tensor Processing Unit), FPGA(Field-Programmable Gate Array)/ASIC(Application-Specific Integrated Circuit) 등 저전력 AI 칩을 활용한다.
- **소프트웨어-하드웨어 공동 최적화:** 로컬에서 AI 연산을 수행해 전력과 보안을 강화하고, 엣지-클라우드 협력으로 전체 에너지 사용을 최적화한다.

온-디바이스 AI는 스마트폰·IoT·웨어러블 등에서 데이터를 로컬에서 처리함으로써, 전력과 네트워크 비용을 줄이며, 보안성을 높인다. 이는 실시간 전력 모니터링과 네트워크 협업을 통해 탄소 배출을 줄이는 지속가능한 AI 처리 방법으로 주목받고 있다.

5. 데이터센터 및 AIOps 기반 지속가능 전략

데이터센터에선 AI 학습·추론을 위해 막대한 전력이 사용되며, 이를 효율적으로 관리하기 위해 다양한 전략이 채택되고 있다.

- **친환경 데이터센터 구축:** 구글, 아마존(Amazon)은 데이터센터에 태양광·풍력 등 재생 에너지를 적극 도입하고 ESS(에너지저장장치, Energy Storage System)를 연계해 전력 공급을 안정화하고 있다.
- **AIOps 기반 운영 최적화:** 실시간 전력 소비 모니터링, 이상 탐지, AI 기반 운영 자동화를 통해 에너지를 절감하고 탄소 배출을 줄인다.

데이터센터의 PUE(전력사용효율, Power Usage Effectiveness), CUE(탄소사용효율, Carbon Usage Effectiveness) 등은 ISO/IEC 30134 시리즈 표준에 의해 정의되며, 이러한 운영 데이터는 ISO 14064에 따라 탄소 보고서로 제출될 수 있다.

6. ICT 국제 표준화 및 시험인증 동향

AI와 ICT의 에너지 문제를 해결하기 위해선 기술적 혁신만으로는 부족하다. 이를 객관적으로 검증하고 상호운용성을 보장할 수 있는 국제 표준화 및 시험·인증 체계가 필수다. 현재 AI 자체의 에너지 효율성을 독립적으로 규제하는 표준은 없지만, 데이터센터·ICT 인

<표 3> 에너지 효율관련 국제표준

표준	제목	내용
ISO/IEC 30134-x	ISO/IEC 30134 series "Information technology — Data centres — Key performance indicators"	데이터센터의 에너지/물/탄소 효율성 KPI
ISO 50001	"Energy management systems — Requirements with guidance for use"	에너지경영시스템(EnMS)
ITU-T L.1305	"Assessment framework for net zero carbon in ICT organizations and ICT services"	데이터센터 에너지 절감 가이드라인
ISO 14064	ISO 14064-1/2/3:2018/2019 "Greenhouse gases — Specification with guidance for quantification, monitoring, reporting and verification"	온실가스 배출량 산정·보고·검증

프라 효율을 다루는 ISO/IEC 30134, ISO 50001과 AI 품질·거버넌스를 다루는 SC42 표준이 AI가 초래하는 에너지 문제를 간접적으로 다루고 있다.

이에 따라 TTA는 ITU-T, ISO/IEC, IEEE 등의 국제표준 동향을 분석해 국내 실정에 맞는 시험·평가·인증 기준을 선제적으로 마련해야 한다. 이를 통해 AI 모델 경량화, AIOps 기반 에너지 관리 기술 신뢰성을 확보하고, 친환경 데이터센터 운영을 위한 표준과 시험 인증체계를 구체화함으로써, 국내 기업의 ESG·EU AI Act 대응과 글로벌 시장 진출 경쟁력을 높여야 한다.

이스 AI, AIOps, 재생에너지 데이터센터 도입은 이제 선택이 아닌 필수다.

이를 뒷받침하기 위해 TTA를 중심으로 ISO/IEC, ETSI, IEEE 표준과 정합성을 갖춘 AI 칩·엣지 장치 시험 및 인증체계(PUE, 추론 전력, 탄소 모니터링 등)를 조속히 구축할 필요가 있다. 향후 기술·표준·시험 인증이 유기적으로 연계될 때, 지속가능한 ICT 환경을 실현할 수 있을 것이다. **TTA**

본 연구는 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원(IITP)의 지원을 받아 수행된 연구임(No. RS-2025-02304333, AX기반 제조·서비스에서 전주기 제로터치를 달성하기 위한 디지털 혁신요소기술 개발)

7. 맺음말

AI의 비약적 발전은 ICT 산업 지속가능성과 직결된다. AI 모델 경량화, 저전력 하드웨어, 엣지·온-디바

참고문헌

- [1] 김말희 외, “인공지능의 에너지 효율화와 엣지 컴퓨팅”, 전자통신동향분석 제40권3호, 2025. pp. 20–29.
- [2] Gartner, “Emerging Tech: Top Trends in Energy-Efficient Generative AI Compute Systems,” Gartner Report, ID G00807709, 2024, pp. 1–12.
- [3] Gartner, “Emerging Tech: Strategies to Achieve Energy Efficiency Goals for GenAI,” Gartner Report, ID G00809640, 2024, pp. 1–7.
- [4] D. Lepikhin et al., “GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding,” in Proceedings of the International Conference on Learning Representations (ICLR), arXiv preprint, CoRR, 2020, arXiv:2006.16668.
- [5] J. Li et al., “DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models,” arXiv preprint, CoRR, vol. 2401, no. 06066, 2024.
- [6] Datature, “A comprehensive guide to neural network model pruning,” Datature Blog, vol. 1, no. 2, Feb. 29, 2024, [Online]. Available: <https://www.datature.io/blog/a-comprehensive-guide-to-neural-network-model-pruning>. [Accessed: Feb. 18, 2025].
- [7] IBM, “Quantization,” IBM Think Blog, vol. 3, no. 1, 2024, [Online]. Available: <https://www.ibm.com/think/topics/quantization>. [Accessed: Feb. 18, 2025].
- [8] J. Gou, B. Yu, S. J. Maybank, and D. Tao, “Knowledge Distillation: A Survey,” arXiv preprint, CoRR, vol. 2006, no. 05525, 2021.
- [9] G. Hinton, O. Vinyals, and J. Dean, “Distilling the Knowledge in a Neural Network,” arXiv preprint, CoRR, vol. 1503, no. 02531, 2015.
- [10] B.-S. Chu and C.-R. Lee, “Low-rank Tensor Decomposition for Compression of Convolutional Neural Networks Using Funnel Regularization,” arXiv preprint, CoRR, vol. 2112, no. 03690, 2021.
- [11] B. Wang, “Tesla Dojo Supercomputers and AI,” NextBigFuture, vol. 5, no. 9, Sep. 22, 2021, [Online]. Available: <https://www.nextbigfuture.com/2021/09/tesla-dojo-supercomputers-and-ai.html>. [Accessed: Feb. 18, 2025].
- [12] ARM, “Ethos-U85,” [Online]. Available: <https://www.arm.com/products/silicon-ip-cpu/ethos/ethos-u85>. [Accessed: Mar. 4, 2025].
- [13] Lightelligence, “PACE: Photonic Arithmetic Computing Engine,” [Online]. Available: <https://www.lightelligence.ai/index.php/product/index/2.html>. [Accessed: Mar. 4, 2025].
- [14] Intel, “Neuromorphic Computing,” [Online]. Available: <https://www.intel.co.kr/content/www/kr/ko/research/neuromorphic-computing.html>. [Accessed: Mar. 4, 2025].

주요 용어 풀이

- 생성형 AI: 텍스트, 이미지, 오디오, 비디오, 코드 등 새로운 콘텐츠를 자동으로 생성하기 위해 대규모 데이터 셋을 학습한 AI 기술
- CBAM(Carbon Border Adjustment Mechanism): 유럽으로 수출하는 제품의 ‘숨은 탄소배출량’에 비용을 부과해, EU 내 탄소규제와의 공정성을 맞추고 글로벌 탄소감축을 유도하는 제도
- CUE(탄소사용효율, Carbon Usage Effectiveness): 데이터센터에서 배출되는 CO₂eq(온실가스 환산량)를 IT 장비의 소비 전력량으로 나눈 값
- EU 인공지능법(AI Act): EU가 세계 최초로 본격 추진하는 AI에 대한 종합적인 법적 규제체계. 2021년 유럽위원회(European Commission)가 최초 제안했으며, 2024년 최종 법안이 유럽 의회와 이사회에서 승인돼 2025년 이후 단계적으로 시행될 예정임
- HBM(High Bandwidth Memory): 메모리를 3D 적층해 초고속 데이터 전송을 가능케 하는 고성능 메모리 기술
- PIM(Processing-In-Memory): 메모리 내부(또는 근처)에서 직접 데이터 연산을 수행함으로써 데이터 이동에 따른 병목과 전력 소모를 줄이는 차세대 컴퓨팅 아키텍처
- PUE(전력사용효율, Power Usage Effectiveness): 데이터센터 전체가 소비하는 전력량을 실제 IT 장비(서버, 스토리지, 네트워크 등)가 소비한 전력량으로 나눈 값